

Google Play App Success Classification : 機器學習模型之實驗與 驗證分析



核心命題與價值定位

哪些特徵與 App 成功關聯性最高？



分類與可解釋性
(Classification & Explainability)


拆解特徵關聯性，
打開機器學習黑盒子。



早期精準預測
(Early Prediction)

盲目追求最高預測準確率
的黑盒子系統。

資料地貌與極端天平挑戰



Failure (83.07%)
9,553 筆



Success (16.93%)
1,947 筆

Target 定義：
 $\text{Installs} \geq 10,000$

核心挑戰：類別不平衡
(Class Imbalance)！
盲目猜測失敗也能
獲得高準確率。



特徵治理：嚴守防呆邊界

15 個原始欄位

防呆機制：
避免目標洩漏！

Target
(目標變數)

Installs

Category

Size

Type

Content
Rating

Genres

Android
Ver

Ad
Supported

8 大核心特徵：Category, Size, Type, Price,
Content Rating, Genres, Android Ver, Ad Supported

App
Name

Current
Ver

Rating

Last
Updated

捨棄干擾

效能現實檢驗：高準確率的陷阱

Logistic Regression

Baseline DT

Random Forest


0.83

Accuracy

Recall

診斷結論：

Logistic Regression 的 Accuracy 雖高達 0.83，但 Precision 與 Recall 均為 0。模型只是盲目將所有 App 預測為失敗，在類別不平衡下，單看 Accuracy 是無效指標。



參數調校與現實權衡 (Trade-off)

手繪混淆矩陣 (Confusion Matrix)

TN：正確預測失敗

1066

FP：誤判為成功

222

FN：錯失的成功

845

TP：正確預測成功

167

Recall
提升至 0.42

Accuracy
下降至
0.536


定調：整體分類能力依然有限，
但已具備足夠的特徵診斷價值。

打開黑盒子 視角一：決策樹 (DT Importance)

Mechanical Decision Tree

分析視角：
基於樹狀分割過程中的
不純度 (Impurity)
下降程度。


初步發現：
模型分類最依賴 Android 版本、
題材與應用類別。



打開黑盒子 視角二：SHAP 解釋力

模型預測

SHAP
(TreeExplainer)

- 
1. Genres (0.145)
 2. Android Ver (0.085)
 3. Category (0.071)

分析視角：
透過 Shapley Value 計算特徵
對輸出的平均絕對貢獻度。

交叉印證：前三名特徵與決
策樹完全一致！

黃金交叉驗證：特徵排名的高度一致性

DT Rank

1. Android Ver

2. Genres

3. Category

4. Size

5. Content Rating

SHAP Rank

1. Genres

2. Android Ver

3. Category

4. Content Rating

5. Size

黃金交叉驗證表
(The Rank Consistency Synthesis)

統計驗證：Spearman 相關係數高達 0.952381 ($p < 0.05$)。

核心萃取：最大排名差異不超過 1 名，雙重視角確立三大核心關聯特徵！

SHAP 方向分析：推動決策的平均傾向



SHAP Direction Compass

⚠ 關鍵備註：
此為 One-Hot 彙整後的整體「平均傾向」，並非單一類別的絕對因果方向！

最高守則 (Red Line Statement)

最高守則：模型關聯性 $\neq$ 因果關係 (Model Association $\neq$ Causality)

Feature Importance 與 SHAP 僅反映模型依賴程度。
絕不能過度解讀為：修改 App 題材或分類，就能直接保證 App 成功。



資料旅程總結：從治理到洞察



嚴謹特徵治理
(避開目標洩漏，
確立 8 大特徵)



誠實效能評估
(拒絕高準確率陷阱，
調校換取診斷價值)



最高一致性與關聯度



雙視角特徵解釋
(DT 與 SHAP 交叉驗證)



感謝聆聽

