

Google Play App Success Classification :

基於 App Features 的機器學習分析

(Google Play App Success Classification:

A Machine Learning Analysis Based on App Features)

中文摘要

本研究以 Google Play App Dataset (Google Play App 資料集) 共 11,500 筆資料為研究對象，探討 App 上架早期即可取得的 App Features (App 特徵) 是否具有 App Success (App 成功) 之預測訊號。本研究將 Installs (安裝數) 達 10,000 次以上定義為 Success = 1，未達門檻者為 Success = 0，形成 Success = 0 占 83.07%、Success = 1 占 16.93% 之 Class Imbalance (類別不平衡) 資料結構。經 Feature Governance (特徵治理) 與 Feature Engineering (特徵工程) 後，本研究建立 11 個正式研究特徵，並排除 Rating、Reviews、Installs 等具 Target Leakage (目標洩漏) 疑慮或上架後始形成之資訊。

資料經 80/20 切割為 Training Set (訓練集) 9,200 筆與 Test Set (測試集) 2,300 筆，並以 ColumnTransformer 建立 Median Imputation (中位數插補)、StandardScaler (標準化)、Most Frequent Imputation (眾數插補) 與 One-Hot Encoding (獨熱編碼) 之前處理流程，將 11 個原始特徵轉換為 97 個 Transformed Features (轉換後特徵)。本研究以 Logistic Regression (邏輯斯迴歸)、Decision Tree (決策樹) 與 Random Forest (隨機森林) 為基礎模型，並透過 Stratified K-Fold Cross Validation (分層 K 折交叉驗證) 進行超參數調校，以 F1 Score (F1 分數) 為主要評估指標。結果顯示，調校後決策樹 (Tuned Decision Tree) 於 Test Set 取得最高 F1 Score 0.2680 (Recall 0.7172、Precision 0.1648、Balanced Accuracy 0.4886)，為候選模型中之 Final Model (最終模型)。

透過 Decision Tree Feature Importance (決策樹特徵重要度) 與 SHAP (SHapley Additive exPlanations) 進行 Model Explainability (模型可解釋性) 分析，結果一致顯示 Size_MB (檔案大小) 為模型中最具重要性之特徵，其次為 Genre_Secondary、Genre_Primary、Content Rating、Android_Min_Version 與 Category。兩種解釋方法於 11 個特徵中有 9 個排名完全一致，Agreement Rate (一致率) 達 81.82%。本研究結論為：早期可取得的 App Features 具有一定之預測訊號，但整體預測能力仍屬有限；上述結果亦受資料品質、Class Imbalance 與特徵範圍等因素限制，實務應用時應審慎解讀，而非直接作為高信賴度之 App 上架決策依據。

關鍵字 Keywords

App Success Classification (App 成功分類)、Feature Governance (特徵治理)、Class Imbalance (類別不平衡)、Decision Tree (決策樹)、SHAP (Shapley Additive exPlanations)

目錄 Table of Contents

章節	頁碼
中文摘要	1
關鍵字 Keywords	1
Chapter 1 緒論	3
Chapter 2 研究背景與相關概念	5
Chapter 3 研究資料與特徵治理	6
Chapter 4 研究方法與資料前處理	8
Chapter 5 機器學習模型建置與評估	10
Chapter 6 研究結果與研究問題分析	12
Chapter 7 研究限制	14
Chapter 8 未來研究方向	15
Chapter 9 結論	16

Chapter 1 緒論

1.1 研究背景

隨著行動裝置與 Mobile Applications（行動應用程式）的普及，Google Play 已成為重要的行動應用程式發布與取得平台。平台上的 App 涵蓋不同類別、內容分級、價格型態、檔案大小、支援版本與廣告支援等多元特徵，使不同 App 在市場中的安裝表現呈現高度差異。對 App 開發者與研究者而言，如何從 App 本身可取得的特徵理解其成功表現，已成為行動應用程式分析的重要議題。

傳統上，App Success（App 成功）可透過安裝數、評分數或評論數等指標衡量。然而，Reviews（評論數）與 Rating（評分）等變數多是在 App 上架並累積使用者互動後才逐漸形成。若研究目的在於探討 App 上線早期即可取得的資訊是否具有成功分類的預測訊號，研究焦點便應放在較早即可取得的 App Features（App 特徵），而非依賴上線後所產生的使用者反應資訊。

基於此觀點，本研究將 Google Play App Success 定義為 Binary Classification Problem（二元分類問題），以 Installs（安裝數）作為建立 Target Variable（目標變數）之依據：安裝數達 10,000 次以上者定義為 Success = 1，低於 10,000 次者為 Success = 0。在 11,500 筆研究資料中，Success = 0 共 9,553 筆，占 83.07%；Success = 1 共 1,947 筆，占 16.93%，資料具有明顯的 Class Imbalance（類別不平衡）特性。

1.2 研究動機

Google Play 平台上的 App 具有高度多樣性，這些 App Features 在發布前後的早期階段即可取得，較適合作為探討早期 App Success 分類訊號的研究對象。本研究希望了解，當不使用 Installs 以外的事後結果資訊作為 Input Features（輸入特徵）時，早期可取得的 App 特徵是否仍能提供分類模型可辨識的預測訊號。

其次，App Success Classification 具有明顯的 Class Imbalance 問題；若僅使用 Accuracy（準確率）評估模型，即使模型傾向預測多數類別，也可能得到相對較高的表面準確率，卻未必能有效辨識 Success = 1 的案例。因此本研究採用 F1 Score 作為主要評估指標，並搭配 Balanced Accuracy（平衡準確率）、Precision（精確率）、Recall（召回率）與 Confusion Matrix（混淆矩陣）進行評估。

此外，單純比較分類結果仍不足以回答哪些 App Features 在模型決策中較為重要，因此本研究進一步納入 Model Explainability（模型可解釋性）分析，透過 Decision Tree Feature Importance 與 SHAP 探討特徵之相對重要性，並檢視兩種方法所得之 Feature Ranking（特徵排名）是否具有一致性。

1.3 研究問題

依據上述動機，本研究提出以下三項 Research Questions（研究問題）：

- **RQ1**：早期可取得的 App Features 是否具有 App Success 的預測能力？
- **RQ2**：哪些早期 App Features 在模型中較為重要？
- **RQ3**：Decision Tree Feature Importance 與 SHAP 的 Feature Ranking 是否一致？

三項研究問題分別對應 Model Evaluation（模型評估）、Feature Importance（特徵重要度）與 SHAP Analysis（SHAP 分析）等研究證據，使 Research Questions、Research Evidence 與 Research Conclusions 形成一致的分析鏈，相關證據與結論將於 Chapter 5、Chapter 6 詳細呈現。

1.4 研究目的

本研究設定以下四項具體 Research Objectives（研究目的）：

1. 分析早期可取得的 App Features 是否具有 App Success 的預測訊號。
2. 比較 Logistic Regression、Decision Tree 及 Random Forest 等 Classification Models（分類模型）的分類表現，並以 F1 Score 選出候選模型中表現較佳者。
3. 利用 Decision Tree Feature Importance 與 SHAP 辨識模型中較具重要性的早期 App Features。
4. 比較兩種 Model Explainability 方法所產生 Feature Ranking 之一致性。

本研究不以建立高準確率模型為唯一目的，而是希望透過分類模型與解釋方法，建立對早期 App Features 與 App Success Classification 之間關聯訊號的實證分析，並在明確研究限制的前提下提供以資料證據為基礎之分析結果。

Chapter 2 研究背景與相關概念

2.1 研究架構

本研究以 Google Play App Dataset 為資料來源，整體 Research Framework（研究架構）由 Data Preparation（資料準備）、Feature Governance、Feature Engineering、Machine Learning Classification（機器學習分類）、Model Evaluation 及 Model Explainability 等階段組成，流程可表示為：

Google Play App Dataset → Data Quality Assessment → Feature Governance → Target Definition → Feature Engineering → Train/Test Split → Data Preprocessing → Machine Learning Classification → Model Evaluation → Final Model Selection → Model Explainability → Research Findings

此架構使 Data Preparation、Machine Learning Classification、Model Evaluation 與 Model Explainability 形成完整分析流程，並分別對應本研究之三項 Research Questions。

2.2 分類模型方法論

本研究採用之分類方法涵蓋線性與非線性兩類模型。Logistic Regression（邏輯斯迴歸）為相對簡單的線性分類方法，可作為觀察特徵是否具有基本分類訊號的基準；Decision Tree（決策樹）透過樹狀分裂建立分類規則，具有能處理數值與類別特徵、且較容易進行 Feature Importance 分析之特性；Random Forest（隨機森林）則是由多棵 Decision Tree 組成的 Ensemble Learning（集成學習）模型，用以觀察集成式樹模型是否優於單一樹模型。

在 Class Imbalance 之研究情境下，模型評估不宜僅依賴 Accuracy，本研究採用以 F1 Score 為核心、Balanced Accuracy 為次要指標，並搭配 Precision、Recall 與 Confusion Matrix 之多指標評估架構；同時透過 Hyperparameter Tuning（超參數調校）與 class_weight（類別權重）設定，觀察模型調整後對少數類別 Success = 1 辨識能力之影響。在模型可解釋性方面，本研究採用 Decision Tree Feature Importance 與 SHAP（SHapley Additive exPlanations）兩種具代表性、原理不同的解釋方法進行交叉檢視：前者反映樹模型分割結構中的特徵重要性，後者則基於 Shapley Value（夏普利值）概念估計特徵對個別預測輸出的邊際貢獻。

Chapter 3 研究資料與特徵治理

3.1 資料集

本研究使用之 Google Play App Dataset 原始共包含 11,500 筆資料與 15 個原始欄位，涵蓋 App 基本資訊、分類、評分、評論、安裝數、檔案大小、價格、內容分級、類型、Android 版本及廣告支援等資訊。

3.2 目標變數定義

本研究以 Installs（安裝數）作為 Target Definition（目標變數定義）之依據：

- Success = 1（若 Installs $\geq 10,000$ ）
- Success = 0（若 Installs $< 10,000$ ）

依此定義，11,500 筆資料中 Success = 0 共 9,553 筆（83.07%），Success = 1 共 1,947 筆（16.93%），呈現明顯的 Class Imbalance。Installs 僅用於建立 Target Variable，並未納入正式 Input Features，以避免 Target Leakage（目標洩漏）：若將用於定義 Success 的變數同時作為模型輸入，模型將能直接取得與目標變數高度重疊的資訊，使模型評估結果失去研究意義。

需特別說明的是，Success = 1 並不代表 App 具有全面性的商業成功，而是本研究所設定 10,000 次安裝門檻下的 Operational Definition（操作性定義）。

3.3 資料品質檢查

本研究於模型建立前進行 Data Quality Assessment（資料品質評估），主要發現如下：

檢查項目	結果
資料總筆數	11,500 筆
Size_MB 缺失值	1,778 筆
Genre_Secondary 缺失值	7,521 筆
Android_Min_Version 缺失值	1,091 筆
Duplicate Rows（重複資料列）	781 筆
Conflicting Pattern Rows（衝突模式資料列）	726 筆
Conflicting Feature Patterns（衝突特徵模式數）	155 組

上述缺失值未在此階段直接刪除，而是留待後續 Preprocessing Pipeline 中之 Imputation（插補）機制處理，以維持研究樣本數；Duplicate Rows 與 Conflicting Patterns 則因研究流程已封存，不在報告整理階段重新刪除或重新訓練模型，而是明確列為 Data Quality Limitation（資料品質限制），並於 Chapter 7、Chapter 8 進一步討論。整體而言，資料具備可進行 Machine Learning Classification 之基本條件，但同時存在的缺失、重複與衝突模式，構成本研究解讀模型結果時應保守看待之重要背景。

3.4 特徵治理

Feature Governance（特徵治理）的目的，是依據變數之資訊性質、研究時間點、與目標變數之關係及資料結構，決定各原始欄位是否適合作為正式模型之 Input Features。

3.4.1 正式輸入特徵（Formal Input Features）

經治理後，本研究最終建立 11 個正式研究特徵：

類別	特徵名稱
分類	Category（類別）
檔案大小	Size_MB（檔案大小）、Size_Varies（檔案大小是否變動）
App 類型與定價	Type（App 類型）、Price（價格）
內容分級	Content Rating（內容分級）
類型	Genre_Primary（主要類型）、Genre_Secondary（次要類型）
Android 相容性	Android_Min_Version（最低 Android 版本）、Android_Varies（Android 版本是否具變異）
廣告	Ad Supported（是否支援廣告）

3.4.2 排除特徵（Excluded Features）

App、Rating、Reviews、Installs、Last Updated、In-App Purchases 與 Current Ver 等原始欄位未納入正式模型。其中 Installs 的排除具最重要的方法論意義，因其為 Target 建立依據，同時納入將產生 Target Leakage；App 欄位具高度識別性；Current Ver 具 High Cardinality（高基數）特性，均不利於作為分類模型之穩定輸入。

3.4.3 特徵治理原則

本研究之特徵治理遵循四項原則：（1）避免 Target Leakage；（2）維持 Early Feature Scope（早期特徵範圍）；（3）降低識別性與高基數變數的影響；（4）維持模型輸入之一致性，即 Train/Test Split、Preprocessing、Model Training、Evaluation 與 Explainability 均以相同正式特徵集合為基礎。透過此設計，本研究之研究問題可明確化為：在排除 Target Variable 所直接提供的資訊後，早期可取得的 App Features 是否仍具有辨識 App Success 的分類訊號？

Chapter 4 研究方法與資料前處理

4.1 特徵工程

本研究針對 Size、Genres 與 Android Ver 三組原始欄位進行 Feature Engineering（特徵工程），將具有不同資訊意義的內容拆分為較明確的變數：

- **Size** → Size_MB（數值型檔案大小）、Size_Varies（大小是否變動，類別型）
- **Genres** → Genre_Primary（主要類型）、Genre_Secondary（次要類型）
- **Android Ver** → Android_Min_Version（最低版本需求）、Android_Varies（版本描述是否具變異）

此拆分使各項 App 特徵能以較明確的變數形式進入模型，並為後續 Feature Importance 與 SHAP 分析提供較清楚的特徵對應關係。經治理與工程後，共形成前述 11 個正式研究特徵。

4.2 資料集切割

完成 Target Definition、Feature Governance 與 Feature Engineering 後，本研究將 11,500 筆完整資料以約 80/20 比例切割為：

資料集	筆數	比例	用途
Training Set（訓練集）	9,200	80%	Model Training、Cross-Validation、Hyperparameter Tuning、Model Selection
Test Set（測試集）	2,300	20%	Final Model Evaluation（僅用於最終評估）

此設計之核心原則為 Test Set Isolation（測試集隔離）：Test Set 不參與模型訓練、超參數調整或模型選擇，僅於模型開發完成後用於最終效能評估，藉此維持評估結果之獨立性。

4.3 資料前處理機制

本研究依 Feature Data Type 將 11 個正式特徵分為 Numerical Features（數值特徵）與 Categorical Features（類別特徵），並以 ColumnTransformer（欄位轉換器）建立一致的 Preprocessing Pipeline（資料前處理流程）：

- **Numerical Features**：Median Imputation（中位數插補）處理缺失值 → StandardScaler（標準化）進行尺度轉換。
- **Categorical Features**：Most Frequent Imputation（眾數插補）處理缺失值 → One-Hot Encoding（獨熱編碼），並設定 `handle_unknown = ignore`，以避免測試資料出現訓練階段未觀察類別時造成轉換錯誤。

上述轉換規則僅以 Training Set 建立，再套用至 Test Set，以降低 Data Leakage（資料洩漏）風險。經前處理後，11 個正式特徵展開為 97 個 Transformed Features（轉換後特徵）：

- X_train_transformed : (9,200, 97)
- X_test_transformed : (2,300, 97)

97 維空間僅為模型計算所使用的表示形式，並不代表研究原始特徵數量增加為 97 個獨立變數；本研究因此區分兩個特徵層級——**Research Feature Level**（11 個正式研究特徵，用於研究問題與結果解釋）與 **Model Representation Level**（97 個轉換後特徵，用於模型實際計算），並於 Chapter 6 之 Model Explainability 分析中，將 97 個轉換後特徵重新映射回 11 個原始特徵。

Chapter 5 機器學習模型建置與評估

5.1 Baseline 模型建立

本研究首先建立 Baseline Models（基準模型），包含 Logistic Regression、Decision Tree，用以建立不同 Machine Learning Algorithms（機器學習演算法）之初始比較基準：Logistic Regression 代表相對簡單的線性分類方法；Decision Tree 用於觀察單一樹模型之非線性分類能力。

5.2 類別不平衡處理策略

由於 Success = 0 占 83.07%、Success = 1 僅占 16.93%，本研究於 Decision Tree 與 Random Forest 之 Hyperparameter Tuning 中納入 `class_weight = balanced` 設定，使模型於訓練過程中提高對少數類別的關注，並以 F1 Score（而非 Accuracy）作為主要模型選擇依據，以降低 Class Imbalance 對模型評估造成之偏差。

5.3 Stratified K-Fold 超參數調校

Hyperparameter Tuning 階段使用 Training Set，透過 StratifiedKFold（分層 K 折交叉驗證）進行模型評估，設定：

- `n_splits = 5`
- `shuffle = True`
- `random_state = 42`

StratifiedKFold 之目的在於維持各 Fold 中 Target Variable 之類別比例。Decision Tree 調整項目包含 `max_depth`、`min_samples_split`、`min_samples_leaf`、`class_weight`；Random Forest 另加入 `n_estimators`。Tuned Decision Tree 最佳參數組合之 5-Fold F1 Score 分別為 0.277978、0.283493、0.286149、0.290323、0.221198，平均為 0.271828，標準差為 0.02563，顯示 Fold 間存在一定程度差異。

最終取得之 Tuned Decision Tree 最佳參數為：

```
class_weight = balanced
max_depth = 5
min_samples_leaf = 5
min_samples_split = 2
random_state = 42
```

5.4 模型比較與評估結果

各候選模型於獨立 Test Set 上之表現整理如下：

表 5-1 候選模型 Test Set 效能比較

模型	Accuracy	Balanced Accuracy	Precision	Recall	F1 Score
Logistic Regression	0.8309	0.5000	0.0000	0.0000	0.0000
Decision Tree (Baseline)	0.7313	0.5087	0.1846	0.1722	0.1782
Tuned Decision Tree (Final)	0.3374	0.4886	0.1648	0.7172	0.2680

模型	Accuracy	Balanced Accuracy	Precision	Recall	F1 Score
Model)					
Tuned Random Forest	0.5087	0.4904	0.1635	0.4627	0.2416

Logistic Regression 之 Accuracy 雖為所有模型最高（0.8309），但 Precision、Recall、F1 Score 均為 0，顯示其幾乎完全將樣本判斷為多數類別 Success = 0，並未有效辨識 Success = 1；此結果驗證了本研究不宜以 Accuracy 作為唯一模型選擇依據之研究設計。Decision Tree Baseline 相較之下已能辨識部分少數類別樣本，F1 Score 提升至 0.1782。

Tuned Decision Tree 之 Confusion Matrix 如下：TN = 497、FP = 1,414、FN = 110、TP = 279。Recall 由 Baseline 的 0.1722 大幅提升至 0.7172，但 Precision 降至 0.1648、Accuracy 降至 0.3374，False Positive 佔所有預測為 Success = 1 樣本之比例約 83.52%，顯示模型以大量 False Positive 換取 Recall 之提升。Tuned Random Forest 之 F1 Score（0.2416）雖低於 Tuned Decision Tree，但 Accuracy 與 Balanced Accuracy 略高，顯示提高模型複雜度未必能直接轉換為較佳之 F1 表現。

5.5 最終模型選擇

依據預先設定之模型選擇準則——F1 Score 最高者為 Final Model——本研究選定 **Tuned Decision Tree** 為最終模型（F1 = 0.2680，為候選模型中最高值）。需強調的是，「最終模型」係指在既定候選模型集合與評估準則下所選出的模型，並不代表其具有高準確度或高度實務預測能力；其優勢主要展現於少數類別 Recall 之提升，而非整體分類正確率。

Chapter 6 研究結果與研究問題分析

6.1 特徵重要性分析 (Decision Tree Feature Importance)

以 Tuned Decision Tree 之 Feature Importance 進行分析，並將 97 個 Transformed Features 彙整回 11 個原始特徵後，結果如下：

表 6-1 Decision Tree Feature Importance (原始特徵層級)

排名	特徵	Feature Importance
1	Size_MB	0.426534
2	Genre_Secondary	0.178136
3	Genre_Primary	0.135912
4	Content Rating	0.126578
5	Android_Min_Version	0.068191
6	Category	0.064649
—	Type、Price、Size_Varies、Android_Varies、Ad Supported	0.000000

其餘 5 個特徵之 Aggregated Feature Importance (彙總特徵重要度) 為 0，僅代表其在目前資料、特徵表示與模型架構下未產生可量化之重要度，不能解釋為完全沒有預測能力。

6.2 SHAP 可解釋性分析

本研究另以 SHAP (SHapley Additive exPlanations, 使用 SHAP 0.52.0 之 TreeExplainer) 針對 Tuned Decision Tree 進行補充分析。SHAP 結果維度為 $2300 \times 97 \times 2$ (Test Set 筆數 $\times$ 轉換後特徵數 $\times$ 類別數)，聚焦 Success = 1 對應之 SHAP 值，並將 97 個 Transformed Features 完整映射 (Unmatched Features = 0) 回 11 個原始特徵。

表 6-2 Aggregated SHAP Feature Importance (原始特徵層級，節錄)

排名	特徵	Mean SHAP
1	Size_MB	0.029380

SHAP 分析同樣顯示 Size_MB 之 Rank (排名) 為第 1，與 Decision Tree Feature Importance 之結果一致。

6.3 Feature Ranking 一致性分析

比較兩種 Model Explainability 方法對 11 個原始特徵之排名結果：11 個特徵中有 9 個排名完全一致，Exact Rank Agreement 為 9/11，Agreement Rate 為 81.82%，Mean Absolute Rank Difference 為 0.3636。部分特徵存在排名差異，例如 Genre_Secondary 於 Decision Tree Feature Importance 排名第 2、SHAP 排名第 4；Content Rating 則分別為第 4 名與第 2 名。整體而言，兩種方法具高度一致性但非完全一致。

6.4 研究問題回應

RQ1：早期可取得的 App Features 是否具有 App Success 的預測能力？

Final Model (Tuned Decision Tree) 於 Test Set 之 F1 Score 為 0.268012、Balanced Accuracy 為 0.488648，Recall 達 0.717224，惟 Precision 僅 0.164796，False Positive Ratio 高達 83.52%。此結果顯示 11 個正式 App Features 確實包含可供分類模型利用之部分訊號，但整體預測能力仍有限。結論：早期可取得的 **App Features** 具有一定的預測訊號，但整體預測能力仍有限。

RQ2：哪些早期 App Features 在模型中較為重要？

Size_MB 在 Decision Tree Feature Importance 與 SHAP 中均排名第一，為模型中最具一致性之高重要性特徵；其次為 Genre_Secondary、Genre_Primary、Content Rating、Android_Min_Version 與 Category。結論：**Size_MB** 為 **Final Model** 中最重要的研究特徵，其餘五項特徵亦具相對較高之模型重要性。

RQ3：Decision Tree Feature Importance 與 SHAP 的 Feature Ranking 是否一致？

兩種方法於 11 個原始特徵中有 9 個排名完全一致，一致率為 81.82%，Mean Absolute Rank Difference 為 0.3636。結論：兩種模型可解釋性方法之整體排名具高度一致性，但並非完全一致。

需特別強調，上述 Feature Importance 與 SHAP 結果僅代表模型中的相對重要性或預測貢獻，並不代表這些特徵與 App Success 之間存在 Causal Relationship（因果關係），亦不能反向推論 Feature Importance = 0 之特徵完全不具預測能力。

6.5 預測系統驗證

為驗證上述正式 Input Schema（輸入欄位規格）與模型流程之一致性，本研究另建立一預測函式 `predict_app_success(app_data)`，其輸入欄位嚴格限制為前述 11 個正式特徵，並排除 App、Rating、Reviews、Installs、Last Updated、In-App Purchases、Current Ver 等欄位（Installs 僅用於建立 Target，不作為 Prediction Input）。以既定示範輸入資料進行測試，模型輸出 Predicted Class = 1，結果與已封存之 Prediction Function Runtime Check 一致，驗證了 Feature Governance 規則於實際推論階段之落實。

Chapter 7 研究限制

本研究結果受到以下五個面向之限制，界定了研究發現之解釋範圍：

（1）**資料品質限制**：資料存在 Size_MB（1,778 筆）、Genre_Secondary（7,521 筆）、Android_Min_Version（1,091 筆）等特徵缺失，以及 781 筆 Duplicate Rows 與 726 筆 Conflicting Pattern Rows（構成 155 組 Conflicting Feature Patterns）。上述問題雖經 Imputation 機制處理以維持樣本數，但插補值並非原始觀測值，且本研究基於既已封存之研究流程，不在報告整理階段重新刪除資料或重新訓練模型。

（2）**目標變數定義與類別不平衡限制**：Installs $\geq 10,000$ 之門檻屬本研究操作性定義，並非 App Success 之唯一判定方式；Success = 1 僅占 16.93%，構成明顯 Class Imbalance，研究結論應限定於此定義與類別分布下。

（3）**特徵範圍限制**：本研究僅分析 11 個 Early-available App Features，未涵蓋 User Feedback（使用者回饋）、App Reputation（App 聲譽）、市場競爭、行銷活動等未納入 Dataset 之資訊，亦刻意排除 Rating、Reviews 等上架後始形成或具 Target Leakage 疑慮之欄位。

（4）**模型效能限制**：Final Model 之 Balanced Accuracy 僅 0.488648，Precision 偏低（0.164796），False Positive Ratio 達 83.52%；5-Fold Cross Validation 之 F1 Score 標準差為 0.025630，Fold 間存在表現差異，故不宜稱模型具高度穩定性。

（5）**模型可解釋性限制**：Decision Tree Feature Importance 與 SHAP 之排名一致率為 81.82%，非完全一致；兩種方法均屬 Model-based Explanation（模型導向解釋），結果僅反映特徵在目前資料與模型結構下之相對重要性，不能作為 Causal Relationship 之證明，亦不應推廣至其他資料集或模型架構。

綜合而言，上述限制並不否定本研究所觀察到的預測訊號，而是界定其解釋範圍：

Early App Features contain some predictive signal, but the overall predictive capability remains limited.

Chapter 8 未來研究方向

針對上述研究限制，本研究提出以下延伸方向：

1. **資料集擴充與資料品質改善**：擴充樣本規模與時間範圍，並針對 Missing Values、Duplicate Rows、Conflicting Feature Patterns 建立更完整之 Data Validation Rules（資料驗證規則），但資料品質改善是否確實提升模型效能，仍應透過獨立實驗驗證，不宜預先假設。
2. **替代性 Success 定義**：比較不同 Installs Threshold（安裝次數門檻）或發展 Multi-class Classification（多類別分類，如低/中/高成功等級），檢驗目前發現對 Target Definition 之敏感程度；任何新定義應視為 New Independent Analysis（新的獨立分析）。
3. **擴充早期可取得特徵**：在維持 Early Availability 原則下，考慮納入更細緻之 App Metadata、階層式 Category/Genre 表示、Pricing/Monetization 細節及 Platform Compatibility 資訊，新增特徵須重新執行 Prediction Time Audit（預測時間稽核）與 Target Leakage Audit（目標洩漏稽核）。
4. **進階類別不平衡處理與模型最佳化**：比較不同 Resampling（重新取樣）方法、Decision Threshold（決策閾值）調整、其他 Ensemble Learning 演算法及更完整之 Hyperparameter Search（超參數搜尋），並同時評估 Precision–Recall Trade-off（精確率與召回率權衡）。
5. **模型穩健性與外部驗證**：透過 Repeated Cross Validation（重複交叉驗證）、子群組穩健性分析、Temporal Validation（時間驗證）及 External Validation（外部驗證，使用不同來源或時間範圍之資料集），檢驗目前發現之 Generalizability（泛化能力）。
6. **延伸模型可解釋性分析**：由 Global Explainability（全域解釋）延伸至 Local Explainability（區域解釋）與 Error Analysis（錯誤分析，如針對 False Positive、False Negative 樣本之 SHAP 分析），並比較 Permutation Importance（置換特徵重要度）等其他解釋方法。

上述方向均應在維持 Feature Governance、Early Availability 與 Target Leakage 控制原則之前提下進行，並以實證結果判斷是否具研究價值，而非預設任何新方法必然改善模型效能。

Chapter 9 結論

本研究以 Google Play App Success Classification 為主題，探討早期可取得之 App Features 是否具有 App Success 之預測能力，並透過 Machine Learning Classification 與 Model Explainability 分析特徵之相對重要性。研究資料共 11,500 筆，經 Feature Governance 建立 11 個正式研究特徵，並以 $\text{Installs} \geq 10,000$ 定義 $\text{Success} = 1$ （1,947 筆，16.93%）、 $\text{Success} = 0$ （9,553 筆，83.07%）。

資料經 80/20 切割（Training Set 9,200 筆、Test Set 2,300 筆）與 ColumnTransformer 前處理後，形成 97 個 Transformed Features。以 F1 Score 為 Primary Metric（主要評估指標）比較 Logistic Regression、Decision Tree 及其調校版本、Random Forest 及其調校版本後，**Tuned Decision Tree** 於 Test Set 取得最高 F1 Score 0.268012（Accuracy 0.337391、Balanced Accuracy 0.488648、Precision 0.164796、Recall 0.717224），為候選模型中之 Final Model。

Feature Importance 與 SHAP 分析一致顯示 **Size_MB** 為模型中最具重要性且最一致之特徵（Feature Importance 0.426534；Mean Absolute SHAP 0.029380，均排名第一），其次為 Genre_Secondary、Genre_Primary、Content Rating、Android_Min_Version 與 Category；兩種解釋方法之 Feature Ranking 一致率達 81.82%（9/11）。

綜合三項研究問題之分析結果，本研究之核心結論為：

可於早期取得的 **App** 特徵具有一定的預測訊號，但整體預測能力仍有限。

此結論同時反映本研究之實證發現與研究限制。本研究之價值並非建立一個高準確率之 App Success 預測系統，而是透過嚴謹之 Feature Governance、多指標模型評估架構與雙重模型可解釋性分析，確立早期 App Features 與 App Success Classification 之間之關聯訊號及其分類價值，並為後續資料擴充、特徵延伸、模型穩健性驗證與可解釋性深化研究提供實證基礎。