



Google Play App Success Classification : 基於 App Features 的機器學習分析



上架初期（無評論、無評分）



核心懸念：
早期特徵能預測成功嗎？



市場結果（是否成功？）



探討在排除「事後結果資訊」的前提下，早期可取得的
App 特徵是否仍提供分類模型可辨識的預測訊號。

成功門檻與失衡的天平



Success = 1
Installs $\geq 10,000$
(16.93%, 共 1,947 筆)

Success = 0
Installs $< 10,000$
(83.07%, 共 9,553 筆)

總計 11,500 筆資料中，呈現極度傾斜的「類別不平衡 (Class Imbalance)」，這是本專案最大的挑戰。

特徵治理：嚴守目標洩漏的安檢門


✓ 保留：11 個早期特徵

✗ 排除：事後資訊



在把資料餵給模型之前，我們的機器人得先扮演嚴格的安檢員，進行「特徵治理」。我們設立了一條紅線：絕對不能讓「事後才會發生的事」偷溜進模型裡。像評論數、評分數，這些都被我們無情地丟進了排除箱。最危險的是「安裝數」本身，因為我們就是用安裝數來定義成功的，如果把安裝數當成特徵丟給模型，就像是在題目卷上一樣，這叫「目標洩漏 (Target Leakage)」。會考全沒用。所以，我們嚴格把關，最後只挑 11 個在 App 上架第一天就能知道的客觀屬性作為正式特徵，確保模型學到的是真本事，而不是作弊。

特徵工程：拆解複合零件



釐清混合資訊，
提供模型更純粹、
明確的決策訊號。


前處理流水線與隔離測試區

11 個包
Feature Blocks

中位數/眾數插補

獨熱編碼
One-Hot Encoding

產出 97
維轉換後特徵




Test Set (20%) - 嚴格隔離區

80% 訓練集用於調整，20% 測試集絕對隔離，確保最終效能評估的獨立性。

模型診斷矩陣：拆穿準確率的假象

模型體檢診斷表


模型	Accuracy	Precision	Recall	F1 Score
Logistic Regression	0.83	0	0	0
Decision Tree	0.73	0.18	0.17	0.17
Tuned Random Forest	0.50	0.16	0.46	0.24



邏輯斯迴歸雖有 83% 準確率，但 F1 為 0（完全無法辨識成功 App）。這證明了必須以 F1 Score 作為評估核心。

最終決擇：調校後決策樹 (Tuned Decision Tree)

優勢：Recall 0.7172
成功捕捉 71% 的潛力 App。




Final Score:
F1 Score 0.2680
(候選最高)

代價：False Positive 83.52%
極高的偽陽性
(Precision 僅 0.1648)。




模型選擇了「寧可錯殺，不可放過」的策略。

特徵重要度：決策樹看重什麼？



回應 RQ2：在排除評論與評分後，「檔案大小」是模型進行早期預測時最依賴的核心訊號。

戴上 SHAP 透鏡：透視模型的黑盒子



不只聽決策樹的一面之詞，我們透過博弈論的 SHAP 值進行雙重驗證，確保特徵排名的客觀性。

雙重驗證：排名一致性矩陣

DT 排名

1. Size_MB
2. Genre_Secondary
3. Genre_Primary
4. Content Rating
5. Price
6. Genre_Se
7. Boot of
8. Gengra
9. Videos
10. Tiudades
11. Tankar
12. TV

相符
(Match)

SHAP 排名

1. Size_MB
2. Genre_Primary
3. Genre_Secondary
4. Price
5. Content Rating
6. Natural
7. Boot of Ano
8. Gengrat
9. V
- 10.
- 11.
- 12.

一致性驗證結果：

- 11 個特徵中有 9 個排名完全一致
- 一致率 (Agreement Rate) : 81.82%
- Mean Absolute Rank Difference: 0.3636

回應 RQ3：跨方法的高度一致性，
強化了特徵重要性洞察的穩健可靠度。

誠實的邊界：研究限制與現實查核



把 App 檔案刻意塞滿變大，並不會自動為你帶來一萬次下載。模型是診斷工具，而非商業決策的神諭。

下一塊藍圖：未來升級方向


擴充特徵維度
(深入探勘 Metadata
與定價策略)



進階失衡處理
(嘗試高階重抽樣與
決策閾值調整)



替代成功定義
(測試 Multi-class
分級指標)



在嚴控「目標洩漏」的前提
下，持續引進新工具，
驗證並探索預測訊號的極限。

感謝聆聽

