

專題研究報告

**Google Play App Success
Classification:**

**基於 App Features 之機器學習分類與模型可解釋性
分析**

Machine Learning Classification and Model Explainability

Based on Google Play App Features

研究資料: Google Play App Dataset (11,500 筆資料)

分析方法: Logistic Regression、Decision Tree、Random Forest、SHAP

目錄

- Chapter 1 緒論 (Introduction)
- Chapter 2 文獻探討與相關技術
- Chapter 3 研究方法 (Research Methodology)
- Chapter 4 實驗結果與分析 (Experimental Results and Analysis)
- Chapter 5 研究發現與討論
- Chapter 6 研究限制 (Research Limitations)
- Chapter 7 結論 (Conclusion)
- Chapter 8 未來研究方向 (Future Work)

(如需自動頁碼目錄，請於Word 中點選「參考資料 → 目錄 → 更新目錄」)

Chapter 1 緒論 (Introduction)

1.1 研究背景與動機

行動應用程式 (Mobile Application) 市場歷經多年發展，Google Play Store 上已累積數量龐大、類型分歧的 App。這些 App 在安裝數量、應用類型、內容分級與商業模式等面向存在明顯差異，如何從既有的 App Characteristics (應用程式特徵) 出發，分析其與 App Success (應用程式成功分類) 之間的關聯，是資料分析與機器學習領域中具有實務價值的問題。

傳統上，App Success 常直接以安裝數量 (Installs) 作為衡量依據。然而若將 Installs 直接當作模型輸入特徵，會形成 Target Leakage (目標洩漏) 的問題——畢竟 Success 本身就是由 Installs 所定義。本研究因此將 Installs 僅用於建立 Target Variable (目標變數)，並不將其納入模型輸入特徵。

在避開目標洩漏的前提下，本研究把重心從單純追求預測準確度，轉向探討一個更根本的問題：哪些 Google Play App Features 與 App Success Classification 具有較高的模型關聯性？換句話說，本研究的核心價值並不在於打造一套高準確率的 App Success Prediction (應用程式成功預測) 系統，而是透過 Machine Learning Classification (機器學習分類) 搭配 Model Explainability (模型可解釋性) 方法，釐清不同 App Features 在 Success Classification 過程中的相對重要程度。

1.2 研究目的

本研究主要目的如下：

1. 建立 Google Play App Success Classification 的研究資料集。
2. 依據 Feature Governance (特徵治理) 原則篩選正式模型輸入特徵。
3. 建立 Success Target (成功目標變數)。
4. 建立 Logistic Regression (邏輯斯迴歸)、Decision Tree (決策樹) 與 Random Forest (隨機森林) 等分類模型。
5. 透過 Hyperparameter Tuning (超參數調校) 改善模型對少數類別的辨識能力。
6. 使用 Decision Tree Feature Importance (決策樹特徵重要度) 與 SHAP (SHapley Additive exPlanations) 進行 Model Explainability。
7. 比較 Decision Tree 與 SHAP 的 Feature Ranking (特徵排名) 一致性。
8. 回答哪些 App Features 與 App Success Classification 具有較高的模型關聯性。

1.3 研究問題 (Research Question)

本研究的核心研究問題為：

「哪些 Google Play App Features 與 App Success Classification 具有較高的模型關聯性？」

本研究刻意不將問題定義為「如何準確預測一個 App 未來是否成功」。這個區分很重要，因為兩者所需要的研究設計截然不同：後者強調預測績效的極大化，前者則著重於特徵層級的關聯性分析。因此，本研究的定位屬於 App Success Classification + Feature Analysis + Model Explainability，而非 Early Prediction（早期預測）研究。

1.4 研究範圍

本研究使用 Google Play App Dataset，資料規模與篩選結果整理如下：

項目	數量／說明
原始資料筆數	11,500 筆 App 資料
原始欄位數	15 個原始欄位
正式模型特徵數	經 Feature Governance 篩選後之 8 個 App Features

整體研究流程涵蓋：Dataset → Feature Governance → Target Definition → Data Preprocessing → Train/Test Split → Baseline Models → Hyperparameter Tuning → Model Evaluation → Feature Importance → SHAP → Rank Consistency → Research Findings，此流程將於第三章逐一說明。

Chapter 2 文獻探討與相關技術

2.1 機器學習分類 (Machine Learning Classification)

Classification (分類) 屬於 Supervised Learning (監督式學習) 的一種，透過已知類別的訓練資料建立分類模型，再將新資料分類至不同的 Target Class (目標類別)。本研究將 App 分為 Success = 0 (未達成功門檻) 與 Success = 1 (達到成功門檻) 兩類，因此屬於 Binary Classification (二元分類) 問題。

2.2 類別不平衡 (Class Imbalance)

本研究的 Target Distribution (目標變數分布) 具有明顯的類別不平衡現象，整理如下表：

Success	筆數	比例
0	9,553	83.07%
1	1,947	16.93%
總計	11,500	100%

Success = 1 僅占 16.93%，這代表模型如果過度偏向多數類別，反而可能取得偏高的 Accuracy (準確率)，卻完全無法有效辨識 Success = 1 的樣本。因此本研究不能只用 Accuracy 評估模型，而必須同時觀察 Balanced Accuracy (平衡準確率)、Precision (精確率)、Recall (召回率) 與 F1 Score (F1 分數)。

2.3 Logistic Regression (邏輯斯迴歸)

Logistic Regression 是常見的二元分類方法，透過輸入特徵估計樣本屬於特定類別的機率。本研究將其作為 Baseline Model (基準模型)，用以建立最基本的分類效能參考點。

2.4 Decision Tree (決策樹)

Decision Tree 以樹狀結構逐步分割資料，使不同類別的樣本能夠被區分開來。本研究採用 Decision Tree 不僅作為分類模型，更因其天生具備 Feature Importance 的計算能力適合作為後續 Feature Analysis 的主要依據。

2.5 Random Forest (隨機森林)

Random Forest 是由多棵 Decision Trees 組成的 Ensemble Learning (集成學習) 方法，本研究將其作為另一個 Baseline Model，用來與 Logistic Regression 及 Decision Tree 進行對照比較。

2.6 SHAP (SHapley Additive exPlanations)

SHAP 是一種 Model Explainability 方法，透過 Shapley Value 的概念分析各特徵對模型輸出的貢獻程度。本研究使用 SHAP 進一步確認三件事：哪些 Features 對模型輸出較為重要、這些 Features 對模型輸出的平均方向為何，以及 Decision Tree Feature Importance 與 SHAP 是否得到相近的 Feature Ranking。

Chapter 3 研究方法（Research Methodology）

3.1 資料集（Dataset）

本研究使用 Google Play App Dataset 作為研究資料來源，共包含 11,500 筆 App 資料與 15 個原始欄位，欄位內容涵蓋 App、Category、Rating、Reviews、Size、Installs、Type、Price、Content Rating、Genres、Last Updated、Current Ver、Android Ver、In-App Purchases 與 Ad Supported。資料品質檢查確認全部 11,500 筆資料無 Full Row Duplicates，原始欄位亦無 SQL NULL；但 Rating 存在 5,377 筆缺漏資料，Reviews 呈現高度右偏分布，平均值與中位數存在明顯落差，不宜單純以平均值描述一般 App 的評論量。Installs 原始格式為文字，須先轉換為數值才能用於建立 Target。

本研究的主要目的並非預測 App 的實際下載量，而是透過機器學習分類模型分析不同 App Features 與 App Success Classification 之間的模型關聯性。

3.2 特徵治理（Feature Governance）

本研究進行 Prediction Time Audit（預測時間點稽核），判斷哪些欄位在研究設計上適合作為模型輸入。經審視後，正式模型 Features 共 8 項：

Feature	中文名稱
Category	類別
Size	大小
Type	類型
Price	價格
Content Rating	內容分級
Genres	類型／題材
Android Ver	Android 版本
Ad Supported	是否支援廣告

下列欄位則不納入正式模型：App、Rating、Reviews、Installs、Last Updated、Current Ver、In-App Purchases。其中最關鍵的是 Installs——它不屬於模型輸入 Feature，而是僅用於建立 Success Target，如此可避免 Target Leakage。另外 Current Ver 因具有大量不同版本值，若直接納入模型容易造成高基數類別特徵問題，因此本研究亦未將其納入。透過上述 Feature Governance，可使模型分析聚焦於預先定義之 App Features，並避免將目標變數或研究範圍外資訊直接納入模型。

3.3 目標變數定義 (Target Definition)

本研究將 App Success 定義為二元分類問題，並將 Installs 轉換為數值後建立 Success 目標變數，定義如下：Installs $\geq 10,000 \rightarrow \text{Success} = 1$ ；Installs $< 10,000 \rightarrow \text{Success} = 0$ 。經建立後，Success = 0 共 9,553 筆，占 83.07%；Success = 1 共 1,947 筆，占 16.93%。需要說明的是，此 10,000 installs 的門檻屬於本研究的 Operational Definition（操作性定義），並非所有 App 研究均適用的普遍成功標準。

3.4 資料前處理 (Data Preprocessing)

正式模型共有 8 個原始 Features，依特徵型態分別處理。Price 為 Numerical Feature（數值特徵），採 Median Imputation（中位數插補）搭配 StandardScaler（標準化）進行尺度轉換。其餘 7 個 Features——Category、Size、Type、Content Rating、Genres、Android Ver 與 Ad Supported——屬於 Categorical Features（類別特徵），缺失值以 Most Frequent Imputation（眾數插補）填補，再透過 One-Hot Encoding（獨熱編碼）轉換為數值表示，並設定 handle_unknown='ignore'，避免測試資料出現訓練資料未曾見過的類別時發生轉換錯誤。上述流程透過 ColumnTransformer 建立，使不同類型特徵能分別套用適當的處理方式。完成 One-Hot Encoding 後，原始 8 個 Features 共轉換為 2,673 個 Transformed Features（轉換後特徵），才提供給後續機器學習模型訓練與預測。

3.5 訓練／測試資料切分 (Train/Test Split)

資料採用 80% Training Set + 20% Test Set 的比例切分：

Dataset	Rows
Training Set	9,200
Test Set	2,300

切分方式採用 Stratified Split（分層切分），使 Training Set 與 Test Set 維持相近的 Target Class Distribution。Test Set 全程不參與 Hyperparameter Tuning，僅保留至模型選定後作最終評估，藉此避免測試資料資訊提前滲入模型選擇流程。

3.6 交叉驗證 (Cross-validation)

模型調校階段使用 StratifiedKFold，設定 n_splits = 5、shuffle = True、random_state = 42，在維持類別比例的前提下進行 5-Fold Cross-validation。

3.7 基準模型 (Baseline Models)

本研究建立 Logistic Regression、Decision Tree 與 Random Forest 三種 Baseline Models。Logistic Regression 作為線性分類模型，可用來評估 App Features 與 Success Classification 之間最基本的分類能力；Decision Tree 透過樹狀分割方式進行分類，並具備較佳的模型可解釋性；Random Forest 則由多棵 Decision Trees 組成，作為樹模型之間的比較基準。三種模型皆使用相同的 Training Set、Test Set 與資料前處理流程，確保模型間的比較具有一致性。Baseline Model 的主要目的，是建立後續 Hyperparameter Tuning 的比較基準。

3.8 超參數調校 (Hyperparameter Tuning)

本研究針對 Decision Tree 透過 GridSearchCV（網格搜尋交叉驗證）搭配 5-fold Stratified Cross-validation 進行超參數搜尋，並以 F1 Score 作為主要的模型選擇依據。最終選定之 Tuned Decision Tree 設定如下：class_weight = balanced、max_depth = None、min_samples_leaf = 5、min_samples_split = 2、random_state = 42。其中 class_weight='balanced' 用於反映不同類別的樣本比例，使模型訓練過程不至於僅偏向樣本數較多的類別。Cross-validation 最佳 F1 Score 約為 0.271828。完成調校後，Tuned Decision Tree 僅使用 Training Set 建立模型，並於最後階段以獨立的 Test Set 進行評估。

3.9 模型評估 (Model Evaluation)

本研究使用 Accuracy、Balanced Accuracy、Precision、Recall、F1 Score 與 Confusion Matrix（混淆矩陣）評估分類模型。Accuracy 反映整體分類正確比例，但在 Class Imbalance 之下，單獨使用 Accuracy 可能無法充分反映模型對少數類別 Success = 1 的辨識能力；Balanced Accuracy 同時考量不同類別的辨識能力，可作為 Accuracy 之外的重要補充指標；Precision 衡量模型預測為 Success = 1 的資料中，實際為 Success = 1 的比例；Recall 衡量實際 Success = 1 的資料中，有多少被模型正確辨識；F1 Score 則綜合 Precision 與 Recall，用以衡量兩者之間的整體平衡。

3.10 模型可解釋性 (Model Explainability)

完成模型建立後，本研究進行兩種 Explainability 分析：其一為 Decision Tree Feature Importance，直接取用 Tuned Decision Tree 本身所提供的 impurity-based feature importance（基於不純度的特徵重要性）；其二為 SHAP，使用 TreeExplainer 計算 SHAP values，並以 Mean Absolute SHAP（平均絕對 SHAP 值）衡量各特徵對模型輸出的相對貢獻程度。由於 Categorical Features 經 One-Hot Encoding 後會產生多個 transformed features，本研究進一步將這些特徵層級的重要性與 SHAP 值彙整回原始 8 個 App Features，以進行一致的特徵層級比較，並使用 Rank Difference（排名差異）

與 Spearman Rank Correlation (Spearman 等級相關) 分析兩種解釋方法的排名一致性。需要特別說明的是，Feature Importance 與 SHAP 呈現的都是模型層級的特徵貢獻或關聯性，並不代表 App Features 與 App Success 之間存在因果關係，因此本研究後續一律以「模型關聯性」「相對重要程度」與「模型貢獻」進行解釋，而不描述為因果效果。

Chapter 4 實驗結果與分析 (Experimental Results and Analysis)

4.1 類別分布 (Class Distribution)

在 11,500 筆 App 資料中，Success = 0 共 9,553 筆，占全部資料的 83.07%；Success = 1 共 1,947 筆，占 16.93%，兩類資料比例存在明顯差異，證實本研究資料具有 Class Imbalance 特性。此結果對後續模型評估具有重要影響：若模型主要將樣本分類為 Success = 0，即便取得較高的 Accuracy，仍可能無法有效辨識 Success = 1，因此本研究除 Accuracy 外，亦同時採用 Balanced Accuracy、Precision、Recall 與 F1 Score 進行模型評估。

4.2 基準模型表現 (Baseline Model Performance)

三種 Baseline Models 於 Test Set 的分類結果整理如下：

Model	Accuracy	Balanced Accuracy	Precision	Recall	F1
Logistic Regression	0.830870	0.500000	0.000000	0.000000	0.000000
Decision Tree	0.731304	0.508672	0.184573	0.172237	0.178191
Random Forest	0.766957	0.498392	0.164384	0.092545	0.118421

Logistic Regression 的 Accuracy 為 0.830870，是三種基準模型中最高，但其 Precision、Recall 與 F1 Score 均為 0，代表模型幾乎將所有樣本判定為 Success = 0，完全無法辨識 Success = 1。這說明在本研究的 Class Imbalance 資料條件下，較高的 Accuracy 並不等於較佳的少數類別辨識能力。Decision Tree 能辨識部分 Success = 1 的樣本，F1 Score 為 0.178191；Random Forest 的 Accuracy 雖高於 Decision Tree，但 Recall 僅 0.092545，F1 Score 亦僅 0.118421，顯示其對 Success = 1 的辨識能力反而較弱。整體而言，三種 Baseline Models 均未呈現高度的分類能力，也支持本研究以多項指標而非單一 Accuracy 進行後續分析。

4.3 調校後決策樹模型表現 (Tuned Decision Tree Performance)

Tuned Decision Tree 於 Test Set 的評估結果如下：

Metric	Result
Accuracy	0.536087
Balanced Accuracy	0.493565
Precision	0.165020
Recall	0.429306
F1 Score	0.238401

相較 Baseline Decision Tree，Recall 由 0.172237 提升至 0.429306，F1 Score 由 0.178191 提升至 0.238401，顯示 class_weight 調整後模型對少數類別 Success = 1 的辨識能力確有改善。然而 Accuracy 由 0.731304 降至 0.536087，Balanced Accuracy 亦由 0.508672 微幅降至 0.493565，Precision 由 0.184573 降至 0.165020，代表模型在提升少數類別辨識力的同時，也產生了較多的錯誤分類。本研究不將 Accuracy 的下降視為模型失敗，而是在 Class Imbalance 的研究情境下，觀察模型是否確實改善了對少數類別的辨識能力；整體而言 Tuned Decision Tree 的分類能力仍屬有限。

4.3.1 混淆矩陣分析 (Confusion Matrix)

Actual \ Predicted	0	1
0	1,066	222
1	845	167

其中 True Negative (TN) 為 1,066、False Positive (FP) 為 222、False Negative (FN) 為 845、True Positive (TP) 為 167。模型正確辨識 Success = 1 的樣本僅 167 筆，仍有高達 845 筆實際 Success = 1 的資料被誤判為 Success = 0，顯示模型存在相當程度的 False Negative。此結果與 F1 Score 僅 0.238401、Balanced Accuracy 僅 0.493565 的結果一致，說明模型雖具有部分分類訊號，但尚不足以支持其具有良好的整體分類能力。

4.4 決策樹特徵重要性 (Decision Tree Feature Importance)

將 One-Hot Encoding 後的 transformed features 彙整回原始 8 個 App Features 後，Decision Tree Feature Importance 結果如下：

Rank	Feature	Importance
1	Android Ver	0.318752
2	Genres	0.244897
3	Category	0.141600
4	Size	0.126511
5	Content Rating	0.109653
6	Ad Supported	0.033585
7	Price	0.020374
8	Type	0.004628

前三名為 Android Ver、Genres 與 Category，顯示 Tuned Decision Tree 在進行分類時較多依賴這三項 Features 所提供的資訊。Size 與 Content Rating 分居第四、第五，重要性亦高於 Ad Supported、Price 與 Type；Type 的重要性最低，僅 0.004628。此結果屬於 impurity-based importance，反映的是特徵在決策樹分割過程中的相對重要程度，不應解釋為 Features 對 App Success 具有因果影響。

4.5 SHAP 特徵重要性 (SHAP Feature Importance)

使用 TreeExplainer 計算 SHAP values，並將 2,673 個 transformed features 的 Mean Absolute SHAP 彙整回原始 8 個 App Features 後，結果如下：

Rank	Feature	Mean Absolute SHAP
1	Genres	0.145228
2	Android Ver	0.085833
3	Category	0.071599
4	Content Rating	0.067772
5	Size	0.029124
6	Ad Supported	0.025982
7	Price	0.004428
8	Type	0.001597

SHAP 排名前三名為 Genres、Android Ver 與 Category，與 Decision Tree Feature Importance 的前三名完全相同，僅 Genres 與 Android Ver 的第一、第二名順序互換。這代表兩種模型解釋方法對於哪些 Features 屬於「相對重要」的判斷高度接近，但由於兩者的計算邏輯與數值定義不同，本研究不直接比較數值大小，而以排名一致性作為後續比較重點。

4.6 SHAP 方向分析 (SHAP Direction Analysis)

除貢獻幅度外，本研究進一步以 Mean SHAP（平均 SHAP 值）分析各 Feature 對模型輸出的平均方向，正值代表該特徵平均而言傾向使模型輸出朝 Success = 1 移動，負值則相反：

Feature	Mean SHAP	Direction
Genres	+0.001919	Positive
Android Ver	+0.001801	Positive
Category	+0.016636	Positive
Content Rating	-0.005085	Negative
Size	+0.005746	Positive
Ad Supported	+0.002902	Positive
Price	-0.000176	Negative
Type	+0.000086	Positive

Category 的 Mean SHAP 為 +0.016636，是八項特徵中正向平均值最高者；Content Rating 則為 -0.005085，是負向平均值最明顯的特徵。不過 Positive SHAP 不等於「造成 Success」，Negative SHAP 也不等於「造成 Failure」——由於 Categorical Features 經 One-Hot Encoding 後拆解為多個類別水準，原始 Feature 層級的 Mean SHAP 其實是彙整後的平均方向，不同類別水準之間可能存在相反的方向。

4.6.1 方向強度 (Direction Strength)

本研究另計算 $\text{Direction Strength} = \text{Mean SHAP} \div \text{Mean Absolute SHAP}$ ，用以描述平均方向相對於貢獻幅度的程度。結果顯示 Category (0.232349)、Size (0.197302) 與 Ad Supported (0.111706) 具有相對較明顯的平均方向性；相對地，Genres (0.013212) 與 Android Ver (0.020988) 雖然 Mean Absolute SHAP 較高，Direction Strength 卻十分接近 0，說明這兩項特徵的模型貢獻幅度雖大，但正負方向在不同樣本間變化較大，整體平均方向反而不明顯。這也說明 Feature Importance 與 Direction 是兩個不同的概念：某項特徵可以同時具有高貢獻幅度與弱平均方向。

4.7 決策樹 × SHAP 排名一致性 (DT × SHAP Rank Consistency)

將兩種方法的排名進行整合比較，結果如下：

Feature	DT Rank	SHAP Rank	Difference
Genres	2	1	-1
Android Ver	1	2	+1
Category	3	3	0
Content Rating	5	4	-1
Size	4	5	+1
Ad Supported	6	6	0
Price	7	7	0
Type	8	8	0

統計結果顯示：Exact Rank Match = 50.00%、Mean Absolute Rank Difference = 0.5000、Maximum Rank Difference = 1、Spearman ρ = 0.952381、p-value = 0.000260。所有 Features 的排名差異均不超過 1 名，且 Spearman ρ 高達 0.952381，代表 Decision Tree Feature Importance 與 SHAP 的排名具有高度正向一致性，p-value < 0.05 亦顯示此相關檢驗達統計顯著。

需要特別澄清的是，Exact Rank Match = 50% 並不代表「兩種方法只有 50% 一致」，這個數字僅表示 8 個 Features 中有 4 個取得完全相同的排名。整體排名一致性應以 Spearman Rank Correlation、Mean Absolute Rank Difference 與 Maximum Rank Difference 三者綜合判斷，而非只看 Exact Rank Match 這單一統計量。

Chapter 5 研究發現與討論

5.1 Model Performance Findings

本研究先透過 Logistic Regression、Decision Tree 與 Random Forest 建立 Baseline Models，再以 Hyperparameter Tuning 建立 Tuned Decision Tree 作為主要分析模型。Baseline 結果顯示，Logistic Regression 的 Accuracy 達 0.830870，但 Recall 與 F1 Score 均為 0，說明高 Accuracy 很可能只是模型偏向多數類別所致，並不代表其具備辨識少數類別的能力。經過 class_weight 調整後，Tuned Decision Tree 的 Recall 提升至 0.429306，F1 Score 提升至 0.238401，對 Success = 1 的辨識能力確實有所改善，但 Balanced Accuracy 仍接近 0.5，Precision 也偏低，整體分類效能依舊有限。因此，本研究不將 Tuned Decision Tree 定義為高效能預測模型，而是將其視為進行 Feature Analysis 與 Model Explainability 的分析工具。

5.2 Important App Features

Decision Tree 與 SHAP 兩種方法都指出 Genres、Android Ver 與 Category 是本研究模型中相對重要的前三項 Features。差別僅在於：Decision Tree 將 Android Ver 排名第一、Genres 排名第二；SHAP 則反過來，將 Genres 排名第一、Android Ver 排名第二。至於 Category，兩種方法皆一致排名第三。這代表在本研究的資料集與模型架構下，這三項 Features 具有較高的模型關聯性，且此結論並非僅來自單一分析方法，而是在兩種不同解釋方法下都得到印證。

5.3 SHAP Direction Findings

SHAP Direction Analysis 顯示不同 Features 對模型輸出的平均方向並不一致，但這個結果僅代表模型輸出方向的平均傾向，並非因果方向。尤其對經過 One-Hot Encoding 的 Categorical Features 而言，不應將原始 Feature 層級的平均 SHAP 直接解釋成單一類別的效果——例如 Category 的正向 Mean SHAP，並不能解釋為「所有 Category 都會提高 Success = 1 的機率」，較適當的說法是「Category 彙整後的整體平均模型輸出方向偏向 Success = 1」。因此本研究採取保守立場：SHAP 用於說明模型如何利用 Features，而不是用於證明 Features 的因果效果。

5.4 Explainability Consistency

Decision Tree Feature Importance 與 SHAP 的排名高度一致，Spearman $\rho = 0.952381$ ，Maximum Rank Difference = 1，代表兩種 Explainability 方法對八項 Features 的重要性排序具有高度一致性。也因為如此，Genres、Android Ver 與 Category 並非只在單一分析方法中出現，而是在兩種不同方法下都呈現較高排名，這讓本研究的結論具備一定程度的交叉驗證基礎。

5.5 Research Question Answer

回到本研究的 Research Question——「哪些 Google Play App Features 與 App Success Classification 具有較高的模型關聯性？」——研究結果顯示：在本研究所使用的 Google Play App Dataset、8 項正式 App Features、Success $\geq 10,000$ installs 的 Target Definition，以及 Tuned Decision Tree 模型架構下，Genres、Android Ver 與 Category 呈現較高的模型關聯性。其中 Genres 在 SHAP 排名第 1、Decision Tree 排名第 2；Android Ver 則相反，Decision Tree 排名第 1、SHAP 排名第 2；Category 在兩種方法中皆排名第 3。Decision Tree 與 SHAP 的 Feature Ranking 亦具有高度一致性。

必須強調的是，上述結果屬於 Model Association（模型關聯性），而非 Causality（因果關係）。這個區分貫穿本研究的所有結論，也是理解本研究定位的關鍵。

Chapter 6 研究限制 (Research Limitations)

6.1 Class Imbalance

Success = 1 僅占 16.93%，容易使模型受到多數類別影響。雖然透過 `class_weight='balanced'` 改善了 Recall，但整體分類效能仍有限，這是解讀本研究所有模型結果時都需要放在心上的前提。

6.2 Classification Performance Limited

Tuned Decision Tree 的 Recall 雖有改善，但 Precision、F1 Score 與 Balanced Accuracy 仍偏低，因此本研究不能宣稱模型具有高度分類準確度。

6.3 Feature Importance 不等於 Causality

Feature Importance 與 SHAP 呈現的是模型層級的重要性與貢獻，Feature Importance $\neq$ Causal Effect。研究結果不能解釋為 Genres、Android Ver 或 Category 直接造成 App Success。

6.4 One-Hot Aggregation Limitation

8 個原始 Features 經 One-Hot Encoding 後產生 2,673 個 Transformed Features，將其重新彙整回原始 Feature 雖能回答研究問題，卻也隱藏了個別類別水準之間的差異。未來若要進一步分析究竟是哪一個 Genre、哪一個 Category 或哪一個 Android Version 具有較高影響，必須進行更細緻的 Category-level Analysis（類別水準分析）。

6.5 Dataset / Feature Governance Scope

本研究僅使用目前資料集與經 Feature Governance 篩選後的八項 Features，因此研究結果不能推論為「在所有 Google Play App Features 中，Genres、Android Ver 與 Category 永遠最重要」。較嚴謹的表述是：在本研究資料集、Feature Governance 與模型架構下，這三項 Features 呈現較高的模型關聯性。

6.6 Success Threshold Definition

本研究以 $\text{Installs} \geq 10,000$ 作為 Success Definition，此門檻屬於研究的操作性定義。若未來改變 Threshold，Class Distribution、Model Performance 與 Feature Importance 皆可能隨之改變。

6.7 Rank Correlation Interpretation

Spearman $\rho = 0.952381$ 表示兩種方法的排名具有高度正向相關，但 Rank Correlation 並不代表兩種方法的原始重要性數值完全相同。因此研究應同時觀察 Spearman ρ 、Mean Absolute Rank Difference、Maximum Rank Difference 與 Exact Rank Match，而不能僅依賴單一統計量下結論。

Chapter 7 結論 (Conclusion)

7.1 研究主要結論

本研究以 Google Play App Dataset 為基礎，使用八項 App Features 建立 Success Classification Model，並透過 Tuned Decision Tree 與 Model Explainability 方法分析 App Features 與 Success Classification 的模型關聯性。研究結果主要有四項：

9. 資料存在明顯 Class Imbalance，因此 Accuracy 不能單獨作為模型效能判斷依據。
10. Tuned Decision Tree 透過 Class Weight 調整改善了 Success = 1 的 Recall，但整體分類效能仍有限。
11. Genres、Android Ver 與 Category 在 Decision Tree Feature Importance 與 SHAP 中均位於前三名。
12. Decision Tree 與 SHAP 的 Feature Ranking 具有高度一致性，Spearman $\rho = 0.952381$ ，且最大排名差異僅為 1。

7.2 整體結論

綜合而言，本研究成功建立一套由 Data → Feature Governance → Classification → Model Evaluation → Explainability → Feature Ranking 所組成的完整研究流程。研究最重要的發現並不是模型具有非常高的預測準確度，而是在本研究設定下，Genres、Android Ver 與 Category 是模型進行 App Success Classification 時相對重要的 App Features。Decision Tree Feature Importance 與 SHAP 均得到相近的 Feature Ranking，提供了彼此交叉驗證的結果。

然而，所有結果均應限定在本研究 Dataset、Target Definition、Feature Governance 與 Model Architecture 的範圍內，因此本研究最終結論應維持：Model Association $\neq$ Causality。

本專題最終研究結論可濃縮如下：

本研究以 11,500 筆 Google Play App Dataset 為研究資料，經 Feature Governance 後選取 Category、Size、Type、Price、Content Rating、Genres、Android Ver 與 Ad Supported 八項 App Features，並以 Installs $\geq 10,000$ 定義 Success = 1。研究透過 Logistic Regression、Decision Tree 與 Random Forest 建立 Baseline Models，再以 Class Weight 與 Hyperparameter Tuning 建立 Tuned Decision Tree。結果顯示，雖然 Tuned Decision Tree 改善了 Success = 1 的 Recall，但整體 Classification Performance 仍有限。進一步透過 Decision Tree Feature Importance

與 SHAP 進行 Model Explainability，結果均顯示 Genres、Android Ver 與 Category 位於重要 Features 前三名；兩種方法的 Feature Ranking 具有高度一致性，Spearman $\rho = 0.952381$ ，且最大排名差異為 1。綜合而言，在本研究所設定的 Dataset、Target Definition、Feature Governance 與 Model Architecture 下，Genres、Android Ver 與 Category 與 App Success Classification 呈現較高的模型關聯性。然而，此結果代表模型層級的關聯與解釋結果，不應進一步解釋為 Features 對 App Success 具有因果效果

Chapter 8 未來研究方向 (Future Work)

8.1 Class Imbalance 改善

未來可以比較 Oversampling（過度取樣）、Undersampling（欠取樣）、SMOTE（Synthetic Minority Over-sampling Technique）與不同 Class Weight 設定之間的差異，進一步改善模型對少數類別的辨識能力。

8.2 擴充分類模型 (Classification Models)

未來可增加 Gradient Boosting（梯度提升）、XGBoost 及其他適合 Tabular Data（表格型資料）的分類模型，並比較不同模型的 Classification Performance，確認本研究的 Feature Importance 結果是否在不同模型架構下依然穩定。

8.3 Category-level Analysis

未來可從原始 Feature 層級進一步深入至個別類別水準，例如具體是哪些 Genres、哪些 Categories 或哪些 Android Versions 與 Success Classification 具有較高模型關聯，補足本研究在 One-Hot Aggregation 上的限制。

8.4 不同 Success Threshold

未來可以測試不同 Installs Threshold，觀察 Threshold → Class Distribution → Model Performance → Feature Importance 之間的變化關係，藉此檢驗研究結果對 Success Definition 的敏感程度。

8.5 擴充資料集 (Dataset)

未來若能取得不同時間點或更大規模的 Google Play Dataset，可進一步驗證目前研究結果是否具有 Robustness（穩健性）。若 Genres、Android Ver 與 Category 在不同 Dataset 中仍維持較高重要性，將能增加研究結果的穩定性證據。

8.6 Cross-model Explainability

未來可針對不同 Classification Models 分別執行 SHAP，再比較不同模型是否得到相近的 Feature Ranking。若不同模型均指向相似的重要 Features，便能進一步驗證 Feature Importance 結果的 Robustness。

8.7 Feature Interaction Analysis

未來可研究 Genres $\times$ Category、Android Ver $\times$ Category、Size $\times$ Genres 等 Feature Interaction（特徵交互作用），分析多個 Features 同時存在時，模型輸出是否會產生不同於單一特徵各自貢獻加總的變化，補足本研究僅分析單一特徵重要性的侷限。